Comprendre et reproduire le projet Lichess

Guide pédagogique de troisième année • Version du 30 octobre 2026

Ce guide explique les fichiers, les colonnes et les tests du projet. L’objectif est de pouvoir lire le code, modifier une question et reproduire les calculs sans être expert en statistiques ou en programmation. Les explications suivent le notebook et les sections ## Partie des scripts.

Le parcours en cinq parties

Partie 1 : créer les DataFrames utiles et les colonnes temporelles. Partie 2 : écrire la fonction du chi carré et comprendre ses sorties. Partie 3 : appliquer cette fonction à des questions annoncées. Partie 4 : distinguer Fisher exact, régression multiple et loi F de Fisher-Snedecor. Partie 5 : finir par des descriptifs et des graphiques lisibles pour préparer l’interprétation.

Les descriptifs apparaissent en dernier dans ce parcours pédagogique, mais il faut aussi les consulter avant de commenter un test. Une valeur p ne remplace ni les effectifs, ni la lecture des données.

Les fichiers à lire en priorité

Fichier	Rôle
Analyse_data.ipynb	Les explications et les calculs exécutables cellule par cellule.
Nettoyage_donnees.py	Préparer les scores, les familles, les historiques et les sorties.
analyses/Tests_repetition.py	Créer les colonnes de passé puis calculer χ^2 et Fisher exact.
analyses/Regression_multiple.py	Estimer un seul modèle du score et expliquer son test F.
analyses/Analyse_ouvertures.py	Organiser les cinq parties et les descriptifs.
Master_file.py	Lancer le parcours complet et conserver les expériences.

La collecte décrit des joueurs et leurs parties observées. Elle n’est pas un échantillon représentatif de tous les joueurs Lichess. Les résultats restent des associations, jamais des preuves de causalité.

Partie 1 Créer les bonnes bases et colonnes

DataFrame colonne et groupe ne sont pas la même chose

Un DataFrame est une table à deux dimensions. Une colonne contient une valeur par ligne. Une ligne de ce projet représente le point de vue d'un joueur dans une partie. Un même game_id peut donc apparaître pour deux joueurs observés : ces deux lignes ne sont pas deux parties indépendantes.

```
d = frame.sort_values(['user_id', 'timestamp', 'game_id']).copy()
by_user_color = d.groupby(['user_id', 'color'])
d['prev_opening_same_color'] = (
    by_user_color['opening_family'].shift(1)
)
```

La première ligne crée une copie triée. groupby définit les groupes du même joueur et de la même couleur. shift(1) décale les valeurs dans chaque groupe. La dernière instruction crée UNE COLONNE : pour chaque partie, elle contient la famille de la précédente partie observée du même joueur avec la même couleur. Elle ne contient pas une liste de ses parties.

Un exemple à vérifier à la main

Partie	Couleur	Famille	Précédente même couleur	Répétition même couleur
1	Blanc	A	Manquante	Manquante
2	Noir	B	Manquante	Manquante
3	Blanc	A	A	1
4	Blanc	B	A	0

Dans la troisième partie, repeat_same_color vaut 1, mais repeat_all vaut 0 car la partie précédente était de famille B. same_color_consecutive désigne seulement la répétition de la couleur elle-même. Les premières observations et les ouvertures inconnues restent manquantes, jamais codées comme des changements.

Quand crée-t-on un nouveau DataFrame

```
meme_couleur = parties.dropna(
    subset=['repeat_same_color', 'prev_result_same_color']
).copy()
```

Cette sélection crée une sous-base où la comparaison est possible. Son effectif peut être inférieur à celui de la base complète. Les historiques concernent les parties collectées ; ils ne couvrent pas nécessairement toutes les parties réellement jouées entre deux dates.

Préparer les données et reconnaître les ouvertures

Le rôle de Nettoyage_donnees.py

nettoyer_identifiants retire les identifiants absents avant de convertir en texte, normalise les pseudos puis dédoublonne les couples joueur/partie. Les dates non exploitables sont exclues. ajouter_resultats_et_elo crée score, win, is_white, elo_diff et les tranches Elo. associer_ouvertures rapproche les noms du référentiel. construire_historiques calcule le passé, les répétitions et l'expérience observée.

score vaut 1 pour une victoire, 0,5 pour une nulle et 0 pour une défaite. win vaut 1 seulement en cas de victoire. elo_diff est le rating du joueur moins celui de l'adversaire. Une valeur manquante d'Elo reste manquante ; aucune valeur n'est inventée.

Le gros référentiel est conservé

Creation_openings_complet.py réunit les cinq tables officielles a.tsv à e.tsv. La version figée contient 3865 lignes, visibles dans References/openings_complet.csv et .parquet. Les sources et leurs empreintes sont conservées. Ce référentiel ne se limite pas aux ouvertures rencontrées dans la collecte.

Identifier avec cinq ou dix coups complets

Identification_ouvertures.py rejoue les positions avec python-chess. Cinq coups complets correspondent à dix demi-coups, dix coups complets à vingt demi-coups. On retient la variante officielle la plus profonde effectivement atteinte dans cette fenêtre, jamais le nom d'une longue variante sur son seul préfixe.

Une ligne courte peut reconnaître une famille générale. opening_reference_ply indique sa profondeur dans le référentiel ; opening_match_ply indique où sa position a été rencontrée dans la partie. Certaines transpositions sont reconnues. Plusieurs noms pour la même position sont signalés et conservés parmi les candidats.

Les noms reçus par l'API restent séparés dans api_eco et api_opening_name. Les coups absents, invalides, les variantes non standard et les parties trop courtes sont signalés ; une étiquette API ne remplace pas silencieusement une reconnaissance locale impossible.

Pourquoi conserver une base brute

La base brute permet de refaire le nettoyage sans retélécharger les parties. Chaque lancement crée Collectes/<identifiant>/Data et Resultats. Aucun ancien dossier n'est supprimé. Les sorties peuvent être actualisées si l'on relance une cellule dans la même expérience.

Partie 2 Comprendre la fonction du chi carré

Question et hypothèses

Le χ^2 teste l'indépendance de deux variables catégorielles. H0 : elles sont indépendantes. H1 : elles sont associées. Le tableau doit contenir des effectifs entiers, pas des scores moyens ou des pourcentages.

```
observed = pd.crosstab(complete[a], complete[b])
stat, p, ddl, expected = chi2_contingency(
    observed, correction=False
)
```

Pour la case i,j, l'effectif attendu est total de la ligne i × total de la colonne j / n. La statistique est la somme des (observé − attendu)² / attendu. Les degrés de liberté sont (nombre de lignes − 1) × (nombre de colonnes − 1). La correction de Yates est désactivée pour correspondre à la formule de Pearson présentée.

La loi et la valeur p

Sous H0 et lorsque les conditions du test sont satisfaites, la statistique suit approximativement une loi du χ^2 à ddl degrés de liberté. La valeur p correspond à l'aire à droite de la statistique dans cette loi. Elle n'est pas la probabilité que H0 soit vraie. Une grande valeur p ne prouve pas l'absence d'association.

Petit exemple fictif

	Non-victoire	Victoire
Changement	20	10
Répétition	10	20

Sur cette table fictive de 60 observations, les attentes valent toutes 15, le χ^2 vaut environ 6,67 et le V de Cramér vaut 1/3. Ce calcul illustre les formules ; il ne constitue pas un résultat réel sur Lichess.

Que renvoie chi2_details

La fonction renvoie un résumé, les effectifs observés, les attentes et les résidus de Pearson. valid indique seulement que toutes les attentes atteignent le seuil conservateur de 5. Les résidus décrivent les cases qui s'écartent de H0 ; ils ne sont pas automatiquement des tests séparés. Le V de Cramér décrit une taille d'association sans direction.

Le panel contient des parties répétées de joueurs : l'indépendance n'est pas garantie. Les valeurs p restent exploratoires même lorsque les attentes sont suffisantes.

Partie 3 Appliquer les chi carrés et les justifier

Deux questions de base

Résultat précédent × répétition cherche si le comportement de répétition est associé au résultat antérieur. Il ne démontre pas une réaction psychologique. Répétition × résultat courant compare les proportions victoire, nulle et défaite selon que la famille est rejouée ou changée. Il ne démontre pas un effet causal de la répétition.

Quatre populations annoncées

Définition	Historique utilisé
Toutes couleurs	Partie observée immédiatement précédente, quelle que soit la couleur.
Précédente de même couleur	Précédente partie du même joueur avec la couleur actuelle.
Consécutives même couleur	Sous-population où les deux parties observées successives ont la même couleur.
Consécutives couleur changée	Sous-population où les deux parties observées successives ont des couleurs différentes.

Les deux questions sont posées dans ces quatre populations : cela donne huit tests. Deux autres comparent répétition de couleur × résultat et répétition de couleur × répétition d’ouverture. Le tableau principal contient donc dix comparaisons. Ces sous-populations se recouvrent et n’ont pas les mêmes dénominateurs.

Fonction d’application et multiplicité

```
tests, tables, taux, complement = run_repetition_tests(
    clean, output_dir, stratify=False,
    include_sensitivity=False
)
```

La fonction écrit les résumés et les tables observées, attendues et de résidus. index_tables.csv fait le lien entre le numéro de table et la question. Holm corrige la famille des χ^2 dont les attentes sont suffisantes. Cette correction ne résout pas la dépendance entre les observations.

Compléments facultatifs

Les analyses par cadence ou Elo, le filtrage d’une transition par joueur et le bootstrap par joueur restent disponibles comme compléments. Ils ne constituent pas le parcours principal simplifié. Une différence de significativité entre deux groupes ne prouve pas que leurs associations diffèrent statistiquement.

Dans le notebook, un appel direct à chi2_details montre les tables et les hypothèses avant de lancer la batterie. On peut ainsi reproduire une question sans lancer toutes les autres.

Partie 4A Le test exact de Fisher

Pourquoi un autre test

Le test exact de Fisher s'applique ici à un tableau 2×2. H0 pose un odds ratio de population égal à 1 dans un modèle à marges fixées. Le calcul repose sur une loi hypergéométrique et non sur une loi F. Le test bilatéral est choisi avant de regarder la valeur p.

Il est utile quand des petits effectifs rendent l'approximation du χ^2 fragile. Il suppose néanmoins un modèle d'observations indépendantes et ne règle pas les répétitions de joueurs ou les adversaires communs.

Le code essentiel

```
table = pd.crosstab(frame[a], frame[b])
if table.shape == (2, 2):
    odds_ratio, p = fisher_exact(
        table.to_numpy(), alternative='two-sided'
    )
```

fisher_details renvoie la table et le résumé. Si une variable n'a pas deux catégories observées, la valeur p reste manquante avec un diagnostic. Les catégories sont ordonnées pour lire clairement l'odds ratio.

Quatre applications

Pour chacun des historiques toutes couleurs et même couleur : répétition × victoire et victoire précédente × répétition. Une non-victoire regroupe défaites et nulles. Le regroupement est annoncé car ces questions ne sont pas identiques au χ^2 à trois résultats. Holm est appliqué séparément à ces quatre tests de Fisher exact.

Comment lire l'odds ratio

Avec lignes 0=changement puis 1=répétition et colonnes 0=non-victoire puis 1=victoire, l'odds ratio compare les odds de victoire en répétition à celles en changement. Une valeur supérieure à 1 ne signifie pas une augmentation identique de la probabilité de victoire. Une case vide peut donner un odds ratio nul ou infini.

Ne pas confondre les deux Fisher

Fisher exact examine des effectifs catégoriels. Le test F de Fisher-Snedecor compare des composantes de variance dans un modèle de régression. Le premier n'est pas une méthode pour intégrer directement plusieurs covariables : c'est la régression multiple de la page suivante qui le fait.

Partie 4B Régression multiple et loi F

Un modèle volontairement unique

```
score ~ repeat_same_color + elo_diff_100
      + is_white + C(format_partie)
```

La variable à expliquer est le score de la partie. Les variables explicatives sont la répétition à même couleur, l'écart Elo par 100 points, la couleur et la cadence. C(format_partie) crée des indicatrices comparées à une cadence de référence. Les lignes dont ces variables sont absentes sont retirées de l'échantillon du modèle.

Un coefficient de répétition de 0,04 représenterait une différence ajustée de 0,04 point de score entre répétition et changement dans ce modèle, à variables incluses comparables. C'est un exemple de lecture, pas un résultat du projet. Il ne faut pas parler d'effet causal.

Test F global classique

H0 : tous les coefficients hors constante sont nuls. On compare le modèle complet au modèle réduit à la moyenne. Si SCT est la somme des carrés autour de la moyenne, SCR celle des résidus et q le nombre de coefficients testés, F = ((SCT − SCR)/q) / (SCR/ddl résidus). fisher_global_ols calcule cette formule et la valeur p dans la loi F.

La référence F est exacte sous erreurs normales, indépendantes et de variance constante. Le score est ici discret et borné, et les joueurs reviennent : ces hypothèses ne sont pas garanties. Le F classique est donc un repère pédagogique, pas une preuve confirmatoire.

Prudence sur les répétitions

Avec au moins 20 joueurs et assez de groupes, le programme fournit aussi des erreurs-types groupées par joueur et un F de Wald approximatif. Le seuil de 20 est une règle de prudence du projet, pas une garantie. Les adversaires communs ne sont pas corrigés par ce seul regroupement. Les valeurs p groupées restent manquantes quand il y a trop peu de joueurs.

Une variable constante, une colinéarité ou un effectif insuffisant donne le statut non_estimable et une raison explicite. Le R^2 décrit l'ajustement, pas la causalité. Le modèle linéaire peut prédire hors de [0,1] : il est choisi ici pour sa lisibilité, pas comme modèle probabiliste parfait du score.

Partie 5 Descriptifs et graphiques simples

Moyenne dispersion et étendue

```
clean['rating'].mean()
clean['rating'].std(ddof=1)
clean['rating'].median()
clean['rating'].min()
clean['rating'].max()
```

La moyenne résume le centre arithmétique. L’écart-type d’échantillon décrit la dispersion autour de la moyenne et n’est pas un intervalle de confiance sur cette moyenne. La médiane est un centre ordonné. Minimum et maximum indiquent les extrêmes. Avec une seule observation, l’écart-type d’échantillon est manquant ; afficher n est indispensable.

Des moyennes qui s’interprètent directement

mean(win) est le taux de victoire. mean(score) compte les nulles pour un demi-point. mean(repeat_same_color) est le taux de répétition parmi les transitions connues. Les premières parties et ouvertures inconnues ne sont pas au dénominateur de ce dernier taux. Les moyennes par partie donnent davantage de poids aux joueurs très actifs.

Quatre figures

histogramme_elo.png montre la distribution des Elo dans les parties observées. effectifs_resultats.png compte victoires, nulles et défaites. score_par_couleur.png compare les scores moyens des blancs et des noirs. experience_score.png décrit le score selon le nombre de pratiques déjà observées dans la famille et la couleur, avec les effectifs exportés en CSV.

La courbe d’expérience n’est pas une preuve d’apprentissage : les adversaires, la sélection des joueurs, la cadence ou la survie des ouvertures peuvent contribuer à sa forme. L’histogramme des Elo n’est pas une distribution donnant le même poids à chaque joueur.

Que raconter dans le rendu

Commencer par l’échantillon et les effectifs, puis les moyennes et dispersions. Annoncer la question de chaque test. Montrer sa table, le diagnostic des attentes, la valeur p corrigée lorsque prévue et la taille d’association. Pour le modèle, commenter les unités et les variables incluses. Dire « associé à » plutôt que « provoque ».

Le projet conserve les résultats non significatifs ou non estimables : il ne faut pas choisir seulement les petites valeurs p. Les analyses décrivent la collecte et ses limites ; elles ne valident pas un mécanisme causal.

Exécuter le projet et retrouver les résultats

Paramètres et conservation

config_projet.py centralise les pseudos, cadences, tailles de collecte, fenêtre de coups et chemins. Le .env privé peut remplacer les valeurs par défaut. RUN_REGRESSIONS active le modèle multiple. Les secrets restent dans l'environnement ou le .env, jamais dans les documents partagés.

```
python -m pip install -r requirements.txt
python Master_file.py --users-per-seed 1 \
    --games-per-format 20 --opening-moves 10
python -m unittest discover -s tests -v
```

Le master appelle successivement les imports historiques, le référentiel, prepare puis analyze. Chaque lancement crée une nouvelle expérience. Dans Colab, la première cellule installe les dépendances dans un nouveau clone ; redémarrer le noyau lors d'un changement de version pour recharger les modules. Télécharger l'archive finale avant de fermer la session temporaire.

Les fichiers de sortie à lire

Sortie dans Resultats	Lecture
tests_chi2.csv et repetition/	χ^2, Holm, tables observées/attendues, résidus, taux.
fisher/tests_fisher_exact.csv	Fisher exact 2×2 et Holm pour les quatre questions.
regression_multiple_resume.csv	Effectif, statut, R^2, F classique et F de Wald groupé.
regression_multiple_coefficients.csv	Coefficients et inférences groupées lorsqu'elles sont disponibles.
statistiques_descriptives.csv	n, mean, std, median, min et max.
description_*.csv et PNG	Comparaisons de groupes et graphiques simples.

Les tests logiciels utilisent des tableaux connus et des données simulées : ils vérifient le code, pas une conclusion empirique. Ils ne valident pas les accès réels à Lichess ou SSP Cloud. Les fichiers avancés des versions précédentes ne sont pas la référence du parcours principal décrit ici.

Références techniques officielles

SciPy χ^2 : https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.chi2_contingency.html

SciPy Fisher exact : https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.fisher_exact.html

SciPy loi F : https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.f.html

Statsmodels test F : https://www.statsmodels.org/stable/generated/statsmodels.regression.linear_model.RegressionResults.f_test.html